

NorthRiver Executive Report

SQL Applied to Warehouse Analytics | Öffentliche Projektfassung | Stand 9. Oktober 2026

Ergebnis und Nutzen

Das NorthRiver Warehouse ermöglicht Auswertungen zu Umsatz, Kunden und Nutzeraktivität. Die geprüften Bestelldaten enthalten 180 Bestellpositionen aus 178 Bestellungen. Der Gesamtumsatz beträgt 24.614,00 bei 356 verkauften Stück. Die Kontrollsummen der erstellten BI Views stimmen mit diesen Basiswerten überein.

West ist die umsatzstärkste Kundenregion, Furniture die umsatzstärkste Produktkategorie. Die Kaufquote ab hinterlegtem Anmeldedatum beträgt 18,80 %. Den vollständigen geordneten Funnel durchläuft ein Nutzer (0,20 %). Diese Ergebnisse beschreiben den Datensatz; sie erklären keine Ursachen. Die öffentliche Fassung ergänzt die abgeschlossene Prüfungsabgabe.

Aufbau des Warehouses

Die operative Datenbank unterstützt einzelne Bestellvorgänge. Das getrennte Warehouse verbindet die Daten für Analysen, ohne diese Abfragen auf die Checkout Datenbank zu verlagern. Eine Zeile in fact_orders steht für eine Bestellposition. Kunden, Produkte, Channels und Datum werden über Surrogatschlüssel mit der Faktentabelle verbunden.

Für Umsatz und Stückzahl werden die Positionswerte summiert. Bestellungen werden mit COUNT(DISTINCT order_id) gezählt. COUNT(*) würde hier 180 Positionen statt 178 Bestellungen liefern. Die aktuellen Auswertungen verwenden das Schema public in northriver_warehouse.

Geschäftsergebnisse

Auswertung	Ergebnis	Einordnung
Gesamtumsatz	24.614,00	2024 und 2025 zusammen
Region West	8.524,00	Höchster Regionumsatz
Kategorie Furniture	12.455,00	Höchster Kategorieumsatz
Retail Store	7.857,50 31,92 %	Höchster Channel Umsatz
Höchster Kundenumsatz	3.619,00	Ohne Veröffentlichung des Kundennamens

Sechs der zwölf Kunden liegen über dem durchschnittlichen Kundenumsatz von 2.051,17. CTEs zerlegen solche Berechnungen in nachvollziehbare Schritte. Window Functions ergänzen Rangfolgen, Vormonatsvergleiche, laufende Summen und gleitende Durchschnitte.

2024 entfallen 12.951,50 Umsatz auf 91 Bestellungen; 2025 sind es 11.662,50 und 87 Bestellungen. Im Juli 2024 steigt der Umsatz gegenüber Juni um 2.476,50. Das sind einzelne Monatsbeobachtungen, keine belastbare Aussage über einen langfristigen Trend.

Datenqualität und Validierung

Die absichtlich fehlerhaften dq-Tabellen liefern drei erwartete FAIL-Ergebnisse. Dieselben drei Schlüsselregeln bestehen im Analyseschema. Die erweiterte Validierung bestätigt 21 Regeln und meldet 314 Sessions vor dem hinterlegten Anmeldedatum. PASS bei einzelnen Regeln ist kein vollständiger Qualitätsnachweis.

Prüfung	Fehlerhafte Übungsdaten	Saubere Tabellen
Fehlender Kundenschlüssel	5 Positionen Umsatz 458,50	0 PASS
Verwaister Channel	3 Positionen Umsatz 70,00	0 PASS
Doppelter Kundenschlüssel	1 Schlüssel mit 2 Zeilen	0 PASS

Der Kundenschlüssel 17 kommt in dq_dim_customer zweimal vor. Seine 16 Bestellpositionen werden dadurch beim Join verdoppelt: Aus 175 Positionen mit Kundenschlüssel werden 191 Ergebniszeilen. Eine auf eindeutige Schlüssel reduzierte Kundenliste bringt den Join wieder auf 175 Zeilen. Diese Query Korrektur verändert die fehlerhafte Tabelle nicht. Dauerhaft sind die Ursache im Ladeprozess und die Eindeutigkeit der Dimensionsschlüssel zu sichern.

Ein INNER JOIN auf dim_channel lässt drei verwaiste Positionen weg und liefert nur 177 statt 180 Zeilen. Der LEFT JOIN erhält alle 180 und macht den fehlenden Treffer sichtbar. Mit dem Label Unbekannter Channel bleiben die 70,00 Umsatz nachvollziehbar. Verwaiste Referenzen werden mit NOT EXISTS geprüft; fehlende Schlüssel werden separat gezählt.

Kohorten und Funnel

Die Nutzerdaten enthalten 500 Nutzer in zwölf Anmeldekohorten von 2024. Retention zählt Nutzer mit Session ab dim_user.signup_date je Kalendermonat, geteilt durch die Kohortengröße. Monat 1 ist der folgende Kalendermonat. Sessions vor Anmeldung sind ausgeschlossen.

In der Januar-Kohorte sind im Monat 0 ab Anmeldetag 18 von 42 Nutzern aktiv (42,86 %). Im Folgemonat sind es 32 (76,19 %), in Monat 2 25 (59,52 %). Email führt bei Monat-1-Retention mit 68/93 (73,12 %); insgesamt sind 352/500 aktiv (70,40 %).

Funnel-Stufe	Nutzer	Conversion aus Vorstufe
Signup	500	Nicht anwendbar
Browsing	237	47,40 %
Warenkorb	67	28,27 %
Checkout	11	16,42 %
Kauf	1	9,09 %

Kauf ab Anmeldedatum: 94/500 Nutzer (18,80 %), ohne Zwischenstufen. Referral: 22/102 (21,57 %); Paid Search: 23 Käufer. Der geordnete Funnel beginnt beim Signup-Event. Gleiche Zeitstempel sind erlaubt; keine Session- oder Zeitfrist. Das Signup-Event liegt bei 24 Nutzern am Anmeldetag, bei 476 später.

Wiederverwendbare BI Ausgaben

Die folgenden vier Views wurden in der aktuellen Fassung erstellt und kontrolliert. Ihre Granularität bestimmt sinnvolle Summen und Zählungen. Die Detailview verwendet LEFT JOINS; eindeutige Dimensionsschlüssel bleiben Voraussetzung. Der Kategorie-Pivot enthält zusätzlich other_categories, im geprüften Bestand überall 0.

View	Bedeutung einer Zeile	Kontrolle
vw_order_details	Eine Bestellposition	180 Positionen, 178 Bestellungen
vw_region_month_summary	Eine Region je Kalendermonat	Jahresumsätze und Bestellungen stimmen
vw_region_category_pivot	Eine Region mit Kategorieumsätzen und Restkategorie	Regionssummen stimmen
vw_channel_metrics_long	Ein Channel und eine Kennzahl	12 Zeilen; alle drei Summen stimmen

Die Detail View enthält lesbare Merkmale und Kennzahlen. Auf der langen Kennzahlen View müssen Umsatz, Stückzahl und Bestellanzahl getrennt ausgewertet werden. Eine normale View speichert SQL Logik, keine vorberechneten Ergebnisse. Gruppierte Bestellanzahlen dürfen nur addiert werden, wenn eine Bestellung nicht mehreren Gruppen zugeordnet ist.

Performance auf zwei Millionen Zeilen

Die Lasttesttabelle fact_orders_big enthält 2.000.000 Zeilen. Indizes auf order_id und channel_sk sowie der Primärschlüsselindex waren vor den aktuellen Messungen bereits vorhanden. EXPLAIN (ANALYZE, BUFFERS) bestätigt ihre Nutzung; beide Messreihen verwenden dieselbe explizite Spaltenauswahl.

Filter und Plan	Erste Messung	Nach ANALYZE
order_id = 5000 Index Scan, 3 Treffer	1,763 ms	0,437 ms
channel_sk = 1 Bitmap Heap Scan, 499.794 Treffer	170,519 ms	347,807 ms

Die Bestellsuche liefert 3 Treffer per Index Scan. Channel 1 trifft 499.794 Zeilen, rund 25 % der Tabelle; der Bitmap-Zugriff besucht 18.692 Heap-Blöcke. Die Laufzeiten schwanken deutlich. Ein Geschwindigkeitsgewinn durch Indexanlage oder Statistikaktualisierung ist nicht belegt; ein aktueller Vergleich ohne Index fehlt.

Nach ANALYZE schätzt der Planer 2 Bestelltreffer und 489.467 Channeltreffer statt tatsächlich 3 und 499.794. Historische SELECT-*-Einzelmessungen sind in evidence dokumentiert und nicht direkt mit der aktuellen Spaltenauswahl vergleichbar. Cache und Systemlast beeinflussen die Laufzeiten.

Grenzen und nächste Schritte

Die 314 Sessions vor Anmeldung liegen 1 bis 27 Tage vorher, jeweils im Anmeldemonat. Ihre Ursache und die Abweichung zum Signup-Event sind offen. Die Retention schließt sie aus und ergänzt Nullzeilen für beobachtete Kohortenmonate. Der letzte Event-Monat gilt konservativ als unvollständig; dies belegt keine Exportvollständigkeit.

Für weitere Nutzung sollten Datenherkunft, Währung und Veröffentlichungsrechte geklärt sowie Schema und freigegebene Beispieldaten ergänzt werden. Automatische Validierung mit Protokollierung und wiederholte Performance-Messungen unter vergleichbaren Bedingungen sind mögliche nächste Schritte. Die ursprüngliche Prüfungsabgabe bleibt unverändert.